UTS

PEMBELAJARAN MESIN



NAMA : Kayla Nazla Ramadhanty Maskat

NIM : 202431132

KELAS : G

DOSEN : Dr. Dra. Dwina Kuswardani, M.Kom

NO.PC :

ASISTEN : 1. Muhammad Ichwan Fauzi

2. Morgan Immanuel Nainggolan

INSTITUT TEKNOLOGI PLN

TEKNIK INFORMATIKA

2026/2027

DAFTAR ISI

DAFTAR ISI 2
BAB I 4
PENDAHULUAN 4
1.1 Latar Belakang 4
1.2 Rumusan Masalah 4
1.3 Tujuan Masalah 5
1.4 Manfaat Masalah 5
BAB II 7
LANDASAN TEORI 7
2.1 Pengantar Pembelajaran Mesin (Machine Learning) 7
2.2 Exploratory Data Analysis (EDA) dan Pra-Pemrosesan Data 7
2.2.1 Exploratory Data Analysis (EDA) 7
2.2.2 Pra-Pemrosesan Data dan Transformasi Fitur 8
2.3 Algoritma Decision Tree (Pohon Keputusan) 8
2.3.1 Konsep Dasar dan Struktur Pohon 8
2.3.2 Kriteria Pemisahan (Splitting Criteria) - Gini Impurity 9
2.3.3 Masalah Overfitting dan Regularisasi (Pruning) 9
2.4 Algoritma Naïve Bayes (Gaussian Naïve Bayes) 10
2.4.1 Teorema Bayes dan Asumsi Independensi 10
2.4.2 Pendekatan Gaussian Naïve Bayes 10
2.5 Evaluasi Kinerja Model Klasifikasi Biner 11
2.5.1 Structure Confusion Matrix 11
2.5.2 Metrik Evaluasi Turunan 11
BAB III 13
HASIL 13

3.1 Import Library dan Inisialisasi Environment 13
3.2 Memuat Dataset Bank Customer 13
3.3 Exploratory Data Analysis (EDA) dan Pemeriksaan Missing Values 14
3.4 Preprocessing Data - Label Encoding 15
3.5 Pembagian Fitur, Target, dan Train-Test Split 15
3.6 Pemodelan dan Evaluasi Decision Tree 16
3.7 Pemodelan dan Evaluasi Gaussian Naïve Bayes 17
3.8 Visualisasi Heatmap Confusion Matrix 17
3.9 Grafik Bar Perbandingan Akurasi Model 18
3.10 Visualisasi Struktur Pohon Decision Tree 19
3.11 Perbandingan Hasil Kinerja Algoritma 20
3.12 Analisis dan Pembahasan 20
BAB IV 22
PENUTUP 22
4.1 Kesimpulan 22
4.2 Saran 22
DAFTAR PUSTAKA 24

BAB I
PENDAHULUAN

1.1 Latar Belakang

Perkembangan teknologi informasi dan komunikasi di sektor perbankan modern telah memicu pertumbuhan volume data transaksi serta informasi demografis nasabah secara pesat (big data). Lembaga keuangan dan perbankan mengumpulkan jutaan catatan aktivitas nasabah setiap harinya, mulai dari karakteristik usia, jenis pekerjaan, tingkat pendidikan, saldo tabungan, status kepemilikan rumah, hingga riwayat interaksi dalam kampanye pemasaran sebelumnya. Keberadaan basis data yang berukuran sangat besar ini menyimpan potensi informasi implisit yang sangat berharga apabila diolah menggunakan teknik penambangan data (data mining) dan pembelajaran mesin (machine learning).

Salah satu kegiatan krusial dalam operasional perbankan adalah ekspansi produk deposit berjangka (term deposit) melalui strategi direct marketing atau telemarketing. Meskipun demikian, metode pemasaran konvensional yang mengandalkan panggilan telepon acak tanpa segmentasi data sering kali tidak efektif. Pendekatan acak ini berdampak pada tingginya biaya operasional, efisiensi kerja agen telemarketing yang rendah, serta tingkat penolakan yang sangat tinggi dari nasabah karena merasa terganggu oleh penawaran yang tidak relevan. Oleh karena itu, diperlukan suatu mekanisme prediktif yang mampu menyaring dan mengklasifikasikan nasabah potensial secara akurat sebelum panggilan telepon dilakukan.

Pembelajaran mesin terawasi (supervised machine learning) menawarkan solusi komputasional cerdas untuk memecahkan persoalan klasifikasi ini. Dengan memanfaatkan dataset historis kampanye perbankan (04_bank_customers.csv), algoritma klasifikasi dapat mempelajari pola tersembunyi yang membedakan nasabah yang akan menyetujui penawaran deposit berjangka (kelas positif) dari nasabah yang menolak (kelas negatif). Dalam tugas UTS Praktikum Pembelajaran Mesin ini, dua algoritma berbasis pendekatan mendasar tetapi ampuh—yaitu Decision Tree dan Naïve Bayes—diterapkan untuk memodelkan dataset nasabah bank tersebut.

1.2 Rumusan Masalah

Berdasarkan konteks praktikum dan ketentuan yang diberikan, rumusan masalah dalam penelitian ini dirumuskan sebagai berikut:

1. Bagaimana melakukan alur pra-pemrosesan data (data preprocessing) dan analisis eksplorasi data (Exploratory Data Analysis - EDA) yang presisi pada dataset nasabah bank (04_bank_customers.csv), meliputi ekstraksi tipe data, verifikasi keberadaan nilai kosong (missing values), serta transformasi fitur kategorikal menjadi representasi numerik menggunakan teknik Label Encoding?
2. Bagaimana mengimplementasikan, melatih (training), dan memvalidasi model klasifikasi berbasis Decision Tree Classifier (dengan pembatasan kedalaman pohon) dan Gaussian Naïve Bayes Classifier menggunakan pustaka scikit-learn pada Python?
3. Bagaimana tingkat akurasi serta metrik evaluasi prediktif (Precision, Recall, F1-Score, dan matriks kebingungan/Confusion Matrix) dari perbandingan antara algoritma Decision Tree dan Naïve Bayes dalam memprediksi nasabah perbankan yang berlangganan deposit berjangka?

1.3 Tujuan Masalah

Adapun tujuan yang ingin dicapai dari pengerjaan praktikum UTS Pembelajaran Mesin ini adalah:

1. Memahami dan Menguasai Tahapan Preprocessing Data: Mampu melakukan pembersihan data, pengidentifikasian variabel independen (X) dan dependen (y), serta mentransformasikan seluruh variabel kategorikal bertipe object menjadi deretan angka numerik melalui Label Encoding agar memenuhi syarat komputasi matriks machine learning.
2. Mengimplementasikan Pemodelan Supervised Learning: Mampu menyusun kode program berstruktur dalam format Jupyter Notebook (.ipynb) untuk melatih model Decision Tree dan Gaussian Naïve Bayes dengan menerapkan skema pembagian data Train-Test Split berproporsi 80:20 secara terstrata (stratified).
3. Mengevaluasi dan Menganalisis Kinerja Algoritma: Mampu mengestraksi output tabel klasifikasi (classification report), membuat visualisasi diagram heatmap Confusion Matrix, menyajikan diagram batang perbandingan akurasi, serta memotret pola logika keputusan pada visualisasi pohon (plot tree).
4. Memberikan Rekomendasi Algoritma Terbaik: Mengidentifikasi algoritma mana yang memiliki ketahanan (robustness) dan performa terbaik untuk membantu pengambilan keputusan bisnis di dunia nyata.

1.4 Manfaat Masalah

Praktikum ini memberikan manfaat multi-dimensi, baik dari sudut pandang teoritis-akademis maupun praktis-terapan:

1. Manfaat Akademis:
   a. Menambah wawasan dan pemahaman mendalam bagi mahasiswa Teknik Informatika Institut Teknologi PLN mengenai penerapan algoritma klasifikasi supervised learning pada dataset riil perbankan.
   b. Melatih kemampuan analisis data, manipulasi struktur data Python menggunakan pustaka pandas, numpy, dan scikit-learn, serta keterampilan memvisualisasikan data dengan matplotlib dan seaborn.
   c. Mengasah sintesis berpikir kritis dalam membandingkan karakteristik matematis antara metode berbasis aturan logika hierarkis (Decision Tree) dan metode probabilistik Bayesian (Naïve Bayes).
2. Manfaat Praktis (Dunia Industri Perbankan):
   a. Efisiensi Biaya Operasional: Memberikan model prediktif bagi tim pemasaran perbankan untuk menyaring nasabah calon penerima penawaran deposit berjangka, sehingga mengurangi durasi dan biaya panggilan telemarketing yang tidak perlu.
   b. Peningkatan Conversions Rate: Membantu divisi CRM (Customer Relationship Management) perbankan dalam memprioritaskan calon nasabah dengan skor probabilitas tertinggi untuk menyetujui produk deposit berjangka.
   c. Optimasi Pemasaran Terarah: Menemukan fitur-fitur dominan (seperti durasi kontak, saldo rekening, dan riwayat kampanye terdahulu) yang paling memengaruhi keputusan nasabah dalam bertransaksi.

BAB II
LANDASAN TEORI

2.1 Pengantar Pembelajaran Mesin (Machine Learning)

Machine Learning merupakan salah satu cabang dari kecerdasan buatan (Artificial Intelligence) yang memungkinkan komputer mempelajari pola dari data untuk menghasilkan prediksi atau keputusan tanpa harus diprogram secara khusus untuk setiap permasalahan. Proses pembelajaran dilakukan dengan memanfaatkan data sebagai dasar untuk mengenali hubungan antarvariabel dan menemukan pola tertentu.

Secara umum, Machine Learning dibagi menjadi beberapa jenis, yaitu Supervised Learning, Unsupervised Learning, Semi-Supervised Learning, dan Reinforcement Learning. Pada praktikum ini digunakan pendekatan Supervised Learning, yaitu metode pembelajaran yang menggunakan data berlabel sebagai acuan dalam proses pelatihan model.

Permasalahan yang digunakan termasuk klasifikasi biner karena model bertujuan memprediksi apakah nasabah akan berlangganan deposito bank atau tidak. Hasil prediksi terdiri dari dua kelas, yaitu yes dan no. Algoritma yang digunakan adalah Decision Tree dan Gaussian Naïve Bayes untuk mengetahui serta membandingkan kemampuan kedua model dalam melakukan klasifikasi.

2.2 Exploratory Data Analysis (EDA) dan Pra-Pemrosesan Data

Sebelum membangun model Machine Learning, data perlu dipahami dan dipersiapkan terlebih dahulu. Tahapan ini bertujuan memastikan data memiliki struktur yang sesuai, mengetahui karakteristik setiap atribut, serta mengurangi permasalahan yang dapat memengaruhi hasil pemodelan. Proses tersebut meliputi Exploratory Data Analysis (EDA) dan pra-pemrosesan data.

2.2.1 Exploratory Data Analysis (EDA)

Exploratory Data Analysis (EDA) merupakan proses analisis awal yang dilakukan untuk memahami karakteristik dan pola dalam suatu dataset. EDA membantu mengetahui jumlah data, jumlah atribut, tipe data, nilai yang hilang (missing values), serta gambaran statistik dari setiap variabel.

Dalam praktikum ini, EDA dilakukan terhadap dataset nasabah bank yang memiliki 45.211 baris data dan 17 kolom. Pemeriksaan dilakukan menggunakan fungsi seperti df.shape, df.info(), df.describe(), dan df.isnull().sum(). Hasil pemeriksaan tersebut digunakan untuk mengetahui

struktur dataset, tipe data setiap kolom, distribusi nilai, serta memastikan apakah terdapat data kosong yang perlu ditangani sebelum proses pemodelan.

2.2.2 Pra-Pemrosesan Data dan Transformasi Fitur

Pra-pemrosesan data merupakan tahap mempersiapkan dataset agar dapat digunakan oleh algoritma Machine Learning. Tahapan ini dapat mencakup penanganan data kosong, perubahan tipe data, penghapusan data yang tidak diperlukan, serta transformasi atribut ke dalam format yang dapat diproses oleh model.

Pada praktikum ini, transformasi fitur dilakukan menggunakan metode Label Encoding untuk mengubah data kategorikal menjadi bentuk numerik. Sebagai contoh, atribut target yang memiliki nilai no dan yes diubah menjadi angka 0 dan 1. Setelah itu, dataset dibagi menjadi data latih (training data) dan data uji (testing data) dengan perbandingan 80:20. Data latih digunakan untuk membangun model, sedangkan data uji digunakan untuk mengukur kemampuan model dalam memprediksi data yang belum pernah dipelajari.

2.3 Algoritma Decision Tree (Pohon Keputusan)

Decision Tree merupakan algoritma Machine Learning yang digunakan untuk menyelesaikan permasalahan klasifikasi maupun regresi. Algoritma ini bekerja dengan membentuk struktur menyerupai pohon berdasarkan serangkaian aturan keputusan. Setiap percabangan dilakukan berdasarkan atribut tertentu hingga menghasilkan keputusan akhir.

2.3.1 Konsep Dasar dan Struktur Pohon

Struktur Decision Tree terdiri atas tiga bagian utama, yaitu Root Node, Internal Node, dan Leaf Node. Root Node merupakan titik awal yang mewakili atribut pertama dalam proses pengambilan keputusan. Internal Node merupakan titik percabangan yang menunjukkan proses pengujian terhadap atribut tertentu. Sementara itu, Leaf Node merupakan bagian akhir yang menghasilkan keputusan atau kelas prediksi.

Dalam proses pembentukan pohon, algoritma akan memilih atribut yang dianggap paling baik untuk memisahkan data ke dalam kelompok tertentu. Proses tersebut dilakukan secara berulang hingga mencapai kondisi penghentian yang telah ditentukan. Keunggulan Decision Tree adalah hasil model relatif mudah dipahami karena proses klasifikasinya dapat digambarkan melalui aturan percabangan.

2.3.2 Kriteria Pemisahan (Splitting Criteria) - Gini Impurity

Dalam algoritma Decision Tree, proses pemisahan data (splitting) dilakukan untuk memperoleh kelompok data yang semakin homogen berdasarkan kelasnya. Salah satu metode yang digunakan untuk menentukan kualitas pemisahan adalah Gini Impurity.

Gini Impurity digunakan untuk mengukur tingkat ketidakmurnian suatu kelompok data. Semakin kecil nilai Gini Impurity, semakin homogen kelompok tersebut. Rumus perhitungannya adalah:

$$Gini(t) = 1 - \sum_{i=1}^{n} p_i^2$$

Keterangan:

1. $Gini(t)$ = tingkat ketidakmurnian pada node
2. p_i = proporsi data pada kelas-i
3. n = jumlah kelas

Pada klasifikasi biner, nilai Gini Impurity menunjukkan seberapa besar campuran antara kelas yes dan no dalam suatu kelompok data. Decision Tree akan memilih pemisahan yang menghasilkan penurunan ketidakmurnian sehingga proses klasifikasi menjadi lebih baik.

2.3.3 Masalah Overfitting dan Regularisasi (Pruning)

Overfitting merupakan kondisi ketika model terlalu menyesuaikan diri dengan data latih sehingga mampu menghasilkan prediksi yang baik pada data tersebut, tetapi kurang mampu memprediksi data baru. Kondisi ini dapat terjadi apabila struktur pohon terlalu kompleks dan memiliki terlalu banyak percabangan.

Salah satu cara untuk mengurangi overfitting adalah menggunakan teknik regularisasi, seperti membatasi kedalaman pohon (max_depth) atau melakukan pruning. Pruning merupakan proses mengurangi cabang yang dianggap kurang memberikan kontribusi terhadap kemampuan prediksi model.

Pada praktikum ini, parameter max_depth=5 digunakan untuk membatasi kedalaman Decision Tree. Pembatasan tersebut bertujuan menjaga agar struktur pohon tidak terlalu kompleks sehingga model diharapkan dapat melakukan klasifikasi dengan lebih baik terhadap data uji.

2.4 Algoritma Naïve Bayes (Gaussian Naïve Bayes)

Naïve Bayes merupakan algoritma klasifikasi yang menggunakan prinsip probabilitas berdasarkan Teorema Bayes. Algoritma ini memperkirakan kemungkinan suatu data termasuk ke dalam kelas tertentu berdasarkan karakteristik atau atribut yang dimilikinya.

Metode ini memiliki keunggulan dalam proses komputasi yang relatif sederhana dan dapat digunakan untuk klasifikasi dengan jumlah data yang cukup besar. Salah satu jenisnya adalah Gaussian Naïve Bayes yang digunakan untuk menangani atribut numerik dengan asumsi distribusi normal.

2.4.1 Teorema Bayes dan Asumsi Independensi

Teorema Bayes merupakan dasar perhitungan probabilitas dalam algoritma Naïve Bayes. Teorema ini digunakan untuk menghitung peluang suatu kelas berdasarkan informasi atau bukti yang tersedia. Rumus Teorema Bayes adalah:

$$P(Y|X) = \frac{P(X|Y) \times P(Y)}{P(X)}$$

Keterangan:

1. $P(Y|X)$ = probabilitas kelas Y berdasarkan data X.
2. $P(X|Y)$ = probabilitas data X jika diketahui kelas Y.
3. $P(Y)$ = probabilitas awal kelas Y (prior probability).
4. $P(X)$ = probabilitas kemunculan data X.

Naïve Bayes menggunakan asumsi bahwa setiap atribut bersifat independen atau tidak saling bergantung terhadap atribut lainnya ketika kelasnya telah diketahui. Asumsi ini membuat proses perhitungan probabilitas menjadi lebih sederhana. Hasil probabilitas dari setiap kelas kemudian dibandingkan untuk menentukan kelas yang paling mungkin.

2.4.2 Pendekatan Gaussian Naïve Bayes

Gaussian Naïve Bayes merupakan pengembangan dari algoritma Naïve Bayes yang menggunakan distribusi normal atau Gaussian untuk menghitung probabilitas atribut numerik. Metode ini mengasumsikan bahwa nilai setiap atribut numerik pada masing-masing kelas mengikuti distribusi normal.

Perhitungan probabilitas dilakukan dengan mempertimbangkan nilai rata-rata (mean) dan standar deviasi (standard deviation) dari setiap atribut pada masing-masing kelas. Dengan pendekatan tersebut, model dapat memperkirakan peluang suatu nilai numerik termasuk ke dalam kelas tertentu.

Dalam praktikum ini, Gaussian Naïve Bayes digunakan sebagai salah satu model pembanding terhadap Decision Tree. Model dilatih menggunakan data nasabah yang telah melalui proses pra-pemrosesan, kemudian digunakan untuk memprediksi kemungkinan nasabah berlangganan deposito atau tidak.

2.5 Evaluasi Kinerja Model Klasifikasi Biner

Evaluasi model merupakan tahap untuk mengetahui kemampuan algoritma dalam menghasilkan prediksi yang sesuai dengan kondisi sebenarnya. Pada klasifikasi biner, evaluasi dilakukan dengan membandingkan hasil prediksi model terhadap label aktual. Pengukuran ini penting untuk mengetahui tingkat ketepatan model dalam membedakan dua kelas, yaitu yes dan no.

2.5.1 Structure Confusion Matrix

Confusion Matrix merupakan tabel yang digunakan untuk membandingkan hasil prediksi model dengan kondisi sebenarnya. Tabel ini terdiri atas empat komponen utama, yaitu:

1. True Positive (TP): Data yang sebenarnya termasuk kelas positif dan berhasil diprediksi sebagai positif.
2. True Negative (TN): Data yang sebenarnya termasuk kelas negatif dan berhasil diprediksi sebagai negatif.
3. False Positive (FP): Data yang sebenarnya termasuk kelas negatif, tetapi diprediksi sebagai positif.
4. False Negative (FN): Data yang sebenarnya termasuk kelas positif, tetapi diprediksi sebagai negatif.

Dalam praktikum ini, kelas positif adalah nasabah yang berlangganan deposito (yes), sedangkan kelas negatif adalah nasabah yang tidak berlangganan deposito (no). Confusion Matrix digunakan sebagai dasar untuk mengetahui jumlah prediksi yang benar maupun kesalahan prediksi dari masing-masing algoritma.

2.5.2 Metrik Evaluasi Turunan

Selain Confusion Matrix, kinerja model juga diukur menggunakan beberapa metrik evaluasi. Metrik tersebut memberikan gambaran yang lebih lengkap mengenai kemampuan model dalam melakukan klasifikasi.

1. Accuracy merupakan persentase keseluruhan prediksi yang benar dibandingkan dengan jumlah seluruh data.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

2. Precision menunjukkan ketepatan model ketika memprediksi suatu data sebagai kelas positif.

$$Precision = \frac{TP}{TP + FP}$$

3. Recall menunjukkan kemampuan model dalam menemukan seluruh data yang sebenarnya termasuk kelas positif.

$$Recall = \frac{TP}{TP + FN}$$

4. F1-Score merupakan nilai rata-rata harmonis antara Precision dan Recall. Metrik ini digunakan untuk melihat keseimbangan antara ketepatan dan kemampuan model dalam menemukan kelas positif.

$$F1\text{-}Score = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

Keempat metrik tersebut digunakan untuk membandingkan hasil klasifikasi Decision Tree dan Gaussian Naïve Bayes. Penggunaan beberapa metrik diperlukan karena nilai Accuracy saja belum tentu menggambarkan kemampuan model secara menyeluruh, terutama apabila jumlah data pada setiap kelas tidak seimbang.

BAB III
HASIL

3.1 Import Library dan Inisialisasi Environment

Pada cell pertama dilakukan pemanggilan beberapa library Python yang diperlukan selama proses praktikum. Library pandas digunakan untuk membaca dan mengelola dataset, sedangkan numpy mendukung operasi numerik. Library matplotlib.pyplot dan seaborn digunakan untuk membuat visualisasi data. Selanjutnya, beberapa modul dari sklearn digunakan untuk membagi dataset, melakukan transformasi data kategorikal, membangun model Decision Tree dan Gaussian Naïve Bayes, serta menghitung hasil evaluasi.

Setelah seluruh library berhasil dipanggil, program siap digunakan untuk proses pengolahan dan analisis data.

Import Library & Inisialisasi Environment

202431132_Kayla N R Maskat

```
#202431132_Kayla N R Maskat
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import LabelEncoder
from sklearn.tree import DecisionTreeClassifier, plot_tree
from sklearn.naive_bayes import GaussianNB
from sklearn.metrics import accuracy_score, classification_report, confusion_matrix
```

3.2 Memuat Dataset Bank Customer

Pada cell kedua dilakukan proses membaca dataset menggunakan fungsi pd.read_csv(). File yang digunakan adalah 04_bank_customers.csv dengan parameter sep=';'. Parameter tersebut diperlukan karena data dalam file dipisahkan menggunakan tanda titik koma, bukan koma.

Dataset yang berhasil dimuat disimpan ke dalam variabel df. Fungsi df.head() digunakan untuk menampilkan lima baris pertama sebagai pemeriksaan awal terhadap data. Berdasarkan hasil pembacaan, dataset memiliki 45.211 baris dan 17 kolom yang berisi informasi mengenai karakteristik nasabah dan hasil pemasaran deposito bank.

Load Dataset

```
#202431132_Kayla N R MAskat
df = pd.read_csv('04_bank_customers.csv', sep=';')
df.head()
```

202431132_Kayla N R Maskat

	age	job	marital	education	default	balance	housing	loan	contact	day	month	duration	campaign	pdays	previous	poutcome	y
0	58	management	married	tertiary	no	2143	yes	no	unknown	5	may	261	1	-1	0	unknown	no
1	44	technician	single	secondary	no	29	yes	no	unknown	5	may	151	1	-1	0	unknown	no
2	33	entrepreneur	married	secondary	no	2	yes	yes	unknown	5	may	76	1	-1	0	unknown	no
3	47	blue-collar	married	unknown	no	1506	yes	no	unknown	5	may	92	1	-1	0	unknown	no
4	33	unknown	single	unknown	no	1	no	no	unknown	5	may	198	1	-1	0	unknown	no

3.3 Exploratory Data Analysis (EDA) dan Pemeriksaan Missing Values

Cell ketiga digunakan untuk melakukan pemeriksaan awal terhadap struktur dan kelengkapan dataset. Fungsi df.info() menampilkan informasi mengenai jumlah data, nama kolom, tipe data, serta jumlah nilai yang tidak kosong pada setiap atribut. Hasil pemeriksaan menunjukkan bahwa terdapat 7 kolom bertipe numerik (int64) dan 10 kolom bertipe kategorikal (object).

Selanjutnya, fungsi df.isnull().sum() digunakan untuk menghitung jumlah nilai kosong pada setiap kolom. Hasilnya menunjukkan bahwa seluruh atribut memiliki nilai kosong sebanyak 0. Dengan demikian, tidak ditemukan missing values pada dataset sehingga tidak diperlukan penanganan khusus terhadap data kosong sebelum memasuki tahap transformasi.

Exploratory Data Analysis (EDA) & Cek Missing Value

```
#202431132_Kayla N R Maskat
print(df.info())
print(df.isnull().sum())
```

202431132_Kayla N R Maskat

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 45211 entries, 0 to 45210
Data columns (total 17 columns):
 #   Column     Non-Null Count  Dtype
---  ------     --------------  -----
 0   age        45211 non-null  int64
 1   job        45211 non-null  object
 2   marital    45211 non-null  object
 3   education  45211 non-null  object
 4   default    45211 non-null  object
 5   balance    45211 non-null  int64
 6   housing    45211 non-null  object
 7   loan       45211 non-null  object
 8   contact    45211 non-null  object
 9   day        45211 non-null  int64
 10  month      45211 non-null  object
 11  duration   45211 non-null  int64
 12  campaign   45211 non-null  int64
 13  pdays      45211 non-null  int64
 14  previous   45211 non-null  int64
 15  poutcome   45211 non-null  object
 16  y          45211 non-null  object
dtypes: int64(7), object(10)
memory usage: 5.9+ MB
None
```

```
dtypes: int64(7), object(10)
memory usage: 5.9+ MB
None
age          0
job          0
marital      0
education    0
default      0
balance      0
housing      0
loan         0
contact      0
day          0
month        0
duration     0
campaign     0
pdays        0
previous     0
poutcome     0
y            0
dtype: int64
```

3.4 Preprocessing Data - Label Encoding

Pada cell keempat dilakukan proses pra-pemrosesan untuk mengubah data kategorikal menjadi bentuk numerik menggunakan metode Label Encoding. Pertama, dataset disalin ke variabel df_encoded agar data asli pada variabel df tetap tersimpan. Selanjutnya, fungsi select_dtypes() digunakan untuk memilih seluruh kolom yang memiliki tipe data object.

Proses pengubahan dilakukan menggunakan perulangan for dan objek LabelEncoder(). Setiap kategori pada kolom yang dipilih akan diberikan kode berupa angka. Hasil transformasi disimpan kembali ke dalam dataset df_encoded, sedangkan objek encoder disimpan pada label_encoders.

Berdasarkan hasil encoding, sebanyak 10 kolom kategorikal berhasil diubah menjadi numerik, termasuk kolom target y. Pada kolom target, nilai no dikodekan menjadi 0 dan yes menjadi 1. Transformasi ini memungkinkan data kategorikal digunakan dalam proses pemodelan. Namun, angka hasil encoding hanya merupakan representasi kategori dan tidak selalu menunjukkan urutan atau tingkatan tertentu.

Preprocessing Data - Encoding Variable Kategorikal

202431132_Kayla N R Maskat

```
#202431132_Kayla N R Maskat
df_encoded = df.copy()
label_encoders = {}

#Mengambil semua kolom yang bertipe object (kategorikal)
categorical_cols = df_encoded.select_dtypes(include=['object']).columns

#Melakukan encoding untuk setiap kolom kategorikal
for col in categorical_cols:
    le = LabelEncoder()
    df_encoded[col] = le.fit_transform(df_encoded[col])
    label_encoders[col] = le

df_encoded.head()
```

	age	job	marital	education	default	balance	housing	loan	contact	day	month	duration	campaign	pdays	previous	poutcome	y
0	58	4	1	2	0	2143	1	0	2	5	8	261	1	-1	0	3	0
1	44	9	2	1	0	29	1	0	2	5	8	151	1	-1	0	3	0
2	33	2	1	1	0	2	1	1	2	5	8	76	1	-1	0	3	0
3	47	1	1	3	0	1506	1	0	2	5	8	92	1	-1	0	3	0
4	33	11	2	3	0	1	0	0	2	5	8	198	1	-1	0	3	0

3.5 Pembagian Fitur, Target, dan Train-Test Split

Pada cell kelima dilakukan pemisahan antara variabel fitur dan variabel target. Variabel X berisi 16 atribut yang digunakan sebagai dasar prediksi, sedangkan variabel y berisi atribut target yang menunjukkan apakah nasabah berlangganan deposito atau tidak.

Selanjutnya, fungsi train_test_split() digunakan untuk membagi dataset menjadi data latih dan data uji. Parameter test_size=0.2 menentukan bahwa 20% data digunakan sebagai data uji dan 80% sisanya sebagai data latih. Parameter random_state=42 menjaga agar pembagian data dapat direproduksi, sedangkan stratify=y mempertahankan proporsi kelas target pada kedua kelompok data.

Hasil pembagian menghasilkan 36.168 data latih dan 9.043 data uji. Data latih digunakan untuk membangun model, sedangkan data uji digunakan untuk mengukur kemampuan model dalam memprediksi data yang belum digunakan selama pelatihan.

Pemisahan Fitur & Target dan Pembagian Data Train-Test

```
#202431132_Kayla N R Maskat
#Memisahkan Fitur (X) dan Target (y)
X = df_encoded.drop('y', axis=1)
y = df_encoded['y']

#Train-Test Split (80% Train, 20% Test)
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y
)

print(f"Data Latih: {X_train.shape[0]} baris | Data Uji: {X_test.shape[0]} baris")
```

202431132_Kayla N R Maskat

```
Data Latih: 36168 baris | Data Uji: 9043 baris
```

3.6 Pemodelan dan Evaluasi Decision Tree

Pada cell keenam dilakukan pembangunan model klasifikasi menggunakan algoritma Decision Tree melalui DecisionTreeClassifier(). Model menggunakan parameter max_depth=5 untuk membatasi kedalaman pohon keputusan sehingga struktur model tidak terlalu kompleks. Parameter random_state=42 digunakan untuk menjaga konsistensi proses pemodelan.

Proses pelatihan dilakukan menggunakan fungsi fit() dengan data latih. Setelah model selesai dilatih, fungsi predict() digunakan untuk menghasilkan prediksi terhadap data uji. Hasil prediksi kemudian dibandingkan dengan label aktual menggunakan accuracy_score() dan classification_report().

Berdasarkan hasil pengujian, model Decision Tree memperoleh Accuracy sebesar 89,70%. Pada kelas Yes, model menghasilkan Precision sebesar 0,59, Recall sebesar 0,40, dan F1-Score sebesar 0,47. Hasil tersebut menunjukkan bahwa model memiliki ketepatan prediksi keseluruhan yang cukup tinggi, tetapi masih terdapat nasabah yang sebenarnya berlangganan deposito dan belum berhasil dikenali oleh model.

Pemodelan & Evaluasi Algoritma 1: Decision Tree

```
#202431132_Kayla N R Maskat
#Inisialisasi dan pelatihan model Decision Tree
dt_model = DecisionTreeClassifier(max_depth=5, random_state=42)
dt_model.fit(X_train, y_train)

#Prediksi data uji
y_pred_dt = dt_model.predict(X_test)
acc_dt = accuracy_score(y_test, y_pred_dt)

print(f"Akurasi Decision Tree: {acc_dt * 100:.2f}%\n")
print("=== Classification Report Decision Tree ===")
print(classification_report(y_test, y_pred_dt, target_names=['No (0)', 'Yes (1)']))
```

202431132_Kayla N R Maskat

```
Akurasi Decision Tree: 89.70%

=== Classification Report Decision Tree ===
              precision    recall  f1-score   support

      No (0)       0.92      0.96      0.94      7985
     Yes (1)       0.59      0.40      0.47      1058

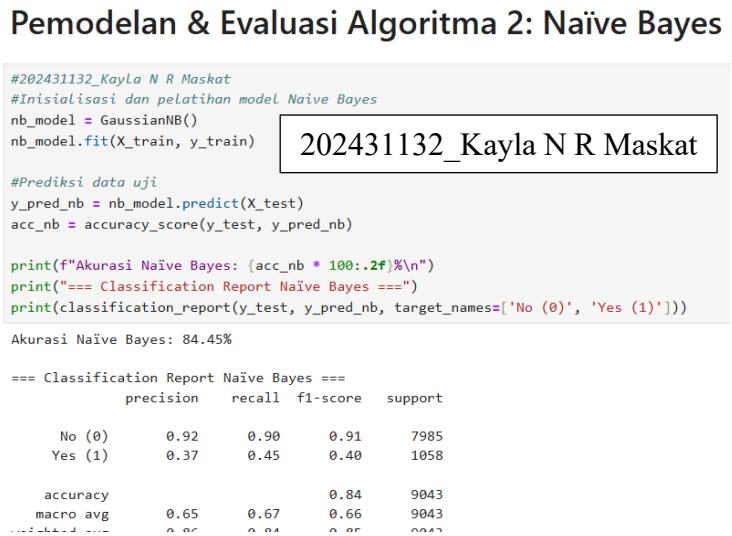
    accuracy                           0.90      9043
   macro avg       0.76      0.68      0.71      9043
weighted avg       0.88      0.90      0.89      9043
```

3.7 Pemodelan dan Evaluasi Gaussian Naïve Bayes

Pada cell ketujuh dilakukan pembangunan model menggunakan algoritma Gaussian Naïve Bayes dengan fungsi GaussianNB(). Algoritma ini menggunakan Teorema Bayes dengan asumsi independensi antarfitur ketika kelas target diketahui. Pendekatan Gaussian digunakan untuk memperkirakan probabilitas berdasarkan distribusi normal pada atribut numerik.

Proses pelatihan dilakukan menggunakan fungsi fit() dengan data latih yang sama seperti pada model Decision Tree. Selanjutnya, fungsi predict() digunakan untuk menghasilkan prediksi terhadap data uji. Hasil prediksi dievaluasi menggunakan accuracy_score() dan classification_report().

Berdasarkan hasil pengujian, Gaussian Naïve Bayes memperoleh Accuracy sebesar 84,45%. Pada kelas Yes, model menghasilkan Precision sebesar 0,37, Recall sebesar 0,45, dan F1-Score sebesar 0,40. Hasil tersebut menunjukkan bahwa model mampu menemukan lebih banyak nasabah yang benar-benar berlangganan deposito dibandingkan Decision Tree berdasarkan nilai Recall, tetapi ketepatan prediksi kelas positifnya masih lebih rendah.



3.8 Visualisasi Heatmap Confusion Matrix

Pada cell kedelapan dilakukan visualisasi hasil evaluasi kedua model menggunakan Confusion Matrix dalam bentuk heatmap. Fungsi confusion_matrix() digunakan untuk menghitung jumlah prediksi benar dan salah, sedangkan sns.heatmap() digunakan untuk menampilkan hasilnya dalam bentuk grafik berwarna. Kedua matriks ditampilkan berdampingan agar hasil Decision Tree dan Gaussian Naïve Bayes lebih mudah dibandingkan.

Pada model Decision Tree diperoleh 7.693 True Negative (TN), 292 False Positive (FP), 639 False Negative (FN), dan 419 True Positive (TP). Sementara itu, Gaussian Naïve Bayes menghasilkan 7.162 TN, 823 FP, 583 FN, dan 475 TP.

Hasil tersebut menunjukkan bahwa Decision Tree lebih baik dalam mengenali nasabah yang tidak berlangganan deposito karena memiliki nilai True Negative lebih tinggi dan False Positive lebih rendah. Sebaliknya, Gaussian Naïve Bayes memiliki True Positive lebih tinggi serta False Negative lebih rendah, sehingga lebih banyak berhasil mengenali nasabah yang berlangganan deposito. Namun, Gaussian Naïve Bayes juga menghasilkan lebih banyak kesalahan prediksi positif.

Visualisasi Confusion Matrix Kedua Algoritma

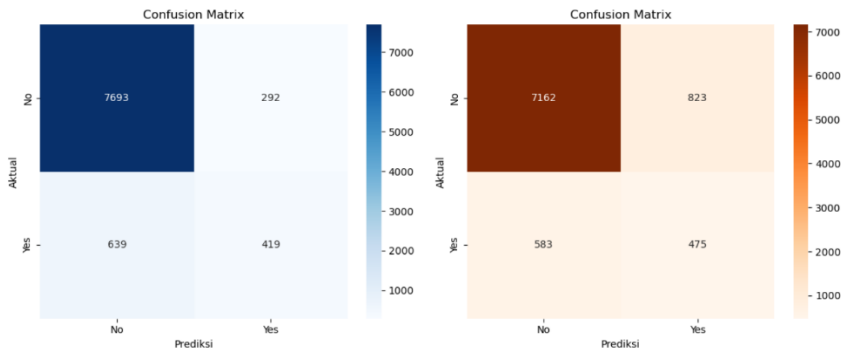
```
#202431132_Kayla N R Maskat
fig, axes = plt.subplots(1, 2, figsize=(12, 5))

#Confusion Matrix Decision Tree
cm_dt = confusion_matrix(y_test, y_pred_dt)
sns.heatmap(cm_dt, annot=True, fmt='d', cmap='Blues', ax=axes[0],
            xticklabels=['No', 'Yes'], yticklabels=['No', 'Yes'])
axes[0].set_title('Confusion Matrix')
axes[0].set_xlabel('Prediksi')
axes[0].set_ylabel('Aktual')

#Confusion Matrix Naive Bayes
cm_nb = confusion_matrix(y_test, y_pred_nb)
sns.heatmap(cm_nb, annot=True, fmt='d', cmap='Oranges', ax=axes[1],
            xticklabels=['No', 'Yes'], yticklabels=['No', 'Yes'])
axes[1].set_title('Confusion Matrix')
axes[1].set_xlabel('Prediksi')
axes[1].set_ylabel('Aktual')

plt.tight_layout()
plt.show()
```

202431132_Kayla N R Maskat



3.9 Grafik Bar Perbandingan Akurasi Model

Pada cell kesembilan dibuat grafik batang untuk membandingkan nilai Accuracy dari kedua algoritma. Variabel models berisi nama algoritma, sedangkan accuracies menyimpan nilai akurasi dalam bentuk persentase. Fungsi plt.bar() digunakan untuk membentuk grafik batang, kemudian plt.text() digunakan untuk menampilkan nilai akurasi di atas setiap batang.

Berdasarkan hasil visualisasi, Decision Tree memperoleh akurasi sebesar 89,70%, sedangkan Gaussian Naïve Bayes memperoleh akurasi sebesar 84,45%. Terdapat selisih sebesar 5,25 poin persentase antara kedua model. Grafik tersebut memperlihatkan bahwa Decision Tree memiliki tingkat ketepatan keseluruhan yang lebih tinggi pada dataset yang digunakan dalam praktikum.

Grafik Bar Perbandingan Akurasi Algoritma

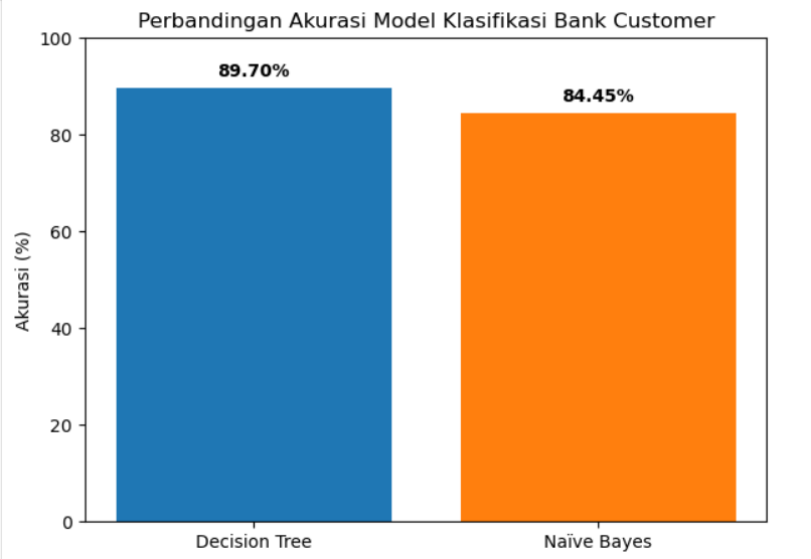
```
#202431132_Kayla N R Maskat
models = ['Decision Tree', 'Naïve Bayes']
accuracies = [acc_dt * 100, acc_nb * 100]

plt.figure(figsize=(7, 5))
bars = plt.bar(models, accuracies, color=['#1f77b4', '#ff7f0e'])
plt.ylim(0, 100)
plt.ylabel('Akurasi (%)')
plt.title('Perbandingan Akurasi Model Klasifikasi Bank Customer')

for bar in bars:
    yval = bar.get_height()
    plt.text(bar.get_x() + bar.get_width()/2, yval + 1.5, f"{yval:.2f}%", ha='center', va='bottom', fontweight='bold')

plt.show()
```

202431132_Kayla N R Maskat



3.10 Visualisasi Struktur Pohon Decision Tree

Pada cell kesepuluh dilakukan visualisasi struktur model Decision Tree menggunakan fungsi plot_tree(). Visualisasi ini bertujuan memperlihatkan proses pengambilan keputusan melalui node dan percabangan berdasarkan atribut yang digunakan dalam klasifikasi.

Parameter feature_names=X.columns digunakan untuk menampilkan nama atribut pada setiap percabangan, sedangkan class_names=['No', 'Yes'] menunjukkan kelas hasil klasifikasi. Parameter filled=True memberikan warna pada node untuk membedakan dominasi kelas, sementara max_depth=3 membatasi kedalaman pohon yang ditampilkan agar visualisasi lebih mudah dibaca.

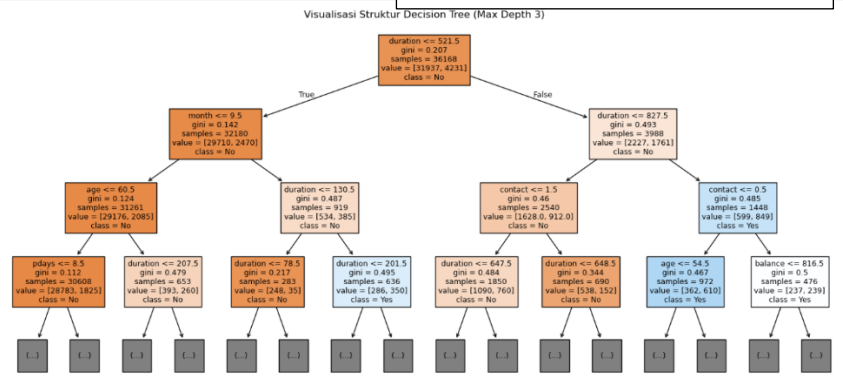
Perlu diperhatikan bahwa pembatasan max_depth=3 pada fungsi visualisasi hanya mengatur tampilan pohon, bukan mengubah model yang telah dilatih dengan max_depth=5. Melalui visualisasi ini, dapat diamati atribut yang digunakan model

dalam membentuk keputusan. Atribut yang muncul pada node awal dan percabangan berikutnya menunjukkan fitur yang dipilih model untuk memisahkan data berdasarkan kriteria tertentu.

Visualisasi Struktur Pohon Keuputusan (Decision Tree Plot)

```
#202431132_Kayla N R Maskat
plt.figure(figsize=(18, 8))
plot_tree(dt_model, feature_names=X.columns, class_names=['No', 'Yes'], filled=True, max_depth=3, fontsize=9)
plt.title('Visualisasi Struktur Decision Tree (Max Depth 3)')
plt.show()
```

202431132_Kayla N R Maskat



3.11 Perbandingan Hasil Kinerja Algoritma

Berdasarkan hasil pengujian, kedua algoritma memiliki kemampuan klasifikasi yang berbeda. Decision Tree memperoleh Accuracy sebesar 89,70%, lebih tinggi dibandingkan Gaussian Naïve Bayes yang memperoleh 84,45%. Selain itu, Decision Tree memiliki nilai Precision dan F1-Score kelas Yes yang lebih tinggi.

Sebaliknya, Gaussian Naïve Bayes memiliki nilai Recall kelas Yes sebesar 0,45, sedikit lebih tinggi dibandingkan Decision Tree sebesar 0,40. Hal ini menunjukkan bahwa Gaussian Naïve Bayes mampu mengenali lebih banyak nasabah yang benar-benar berlangganan deposito, meskipun menghasilkan lebih banyak prediksi positif yang keliru.

Dengan demikian, Decision Tree menunjukkan kinerja yang lebih baik berdasarkan Accuracy, Precision, dan F1-Score. Sementara itu, Gaussian Naïve Bayes dapat menjadi alternatif apabila tujuan klasifikasi lebih menekankan pada kemampuan menemukan nasabah dari kelas positif.

3.12 Analisis dan Pembahasan

Hasil praktikum menunjukkan bahwa Decision Tree lebih unggul dalam melakukan klasifikasi data nasabah bank berdasarkan sebagian besar metrik evaluasi. Hal ini terlihat dari nilai Accuracy sebesar 89,70% serta nilai Precision dan F1-Score kelas Yes yang lebih tinggi dibandingkan Gaussian Naïve Bayes. Struktur pohon keputusan juga memberikan gambaran mengenai atribut yang digunakan model dalam menentukan hasil klasifikasi.

Sementara itu, Gaussian Naïve Bayes memperoleh Recall yang sedikit lebih tinggi. Artinya, model tersebut berhasil mengenali lebih banyak nasabah yang benar-benar berlangganan deposito, tetapi juga menghasilkan lebih banyak kesalahan dalam memprediksi nasabah sebagai kelas positif.

Perbedaan hasil kedua algoritma dapat dipengaruhi oleh karakteristik data dan asumsi masing-masing metode. Decision Tree membentuk aturan berdasarkan pemisahan atribut, sedangkan Gaussian Naïve Bayes menggunakan perhitungan probabilitas dengan asumsi independensi antarfitur. Selain itu, penggunaan Label Encoding pada seluruh atribut kategorikal perlu diperhatikan karena kode angka yang d ihasilkan dapat diperlakukan sebagai nilai numerik oleh Gaussian Naïve Bayes, meskipun kategori aslinya belum tentu memiliki urutan.

Secara keseluruhan, praktikum ini menunjukkan bahwa pemilihan algoritma perlu mempertimbangkan tujuan klasifikasi dan karakteristik dataset. Berdasarkan hasil pengujian yang diperoleh, Decision Tree menjadi model dengan kinerja lebih baik secara keseluruhan, sedangkan Gaussian Naïve Bayes memiliki keunggulan pada nilai Recall kelas positif.

BAB IV
PENUTUP

4.1 Kesimpulan

Berdasarkan seluruh alur praktikum pembelajaran mesin yang telah dilaksanakan pada dataset Bank Customer Direct Marketing (04_bank_customers.csv), dapat disimpulkan bahwa tahapan analisis eksplorasi data (EDA) dan pra-pemrosesan data menggunakan teknik Label Encoding terbukti sukses mentransformasikan 10 variabel kategorikal menjadi representasi numerik bulat tanpa mengabaikan aspek integritas data. Penggunaan metode pembagian data stratified train-test split dengan rasio 80% data latih (36.168 sampel) dan 20% data uji (9.043 sampel) juga berhasil mempertahankan proporsi distribusi kelas target y secara seimbang pada kedua himpunan data.

Dari hasil pengujian dan evaluasi model klasifikasi yang diuji, algoritma Decision Tree (dengan pembatasan kedalaman max_depth=5) terbukti berkinerja lebih unggul dibandingkan algoritma Gaussian Naïve Bayes. Model Decision Tree berhasil mencatatkan tingkat akurasi sebesar 89,70%, dengan nilai Precision sebesar 0,59, Recall sebesar 0,40, dan F1-Score sebesar 0,47 pada prediksi kelas positif nasabah yang menyetujui penawaran deposit berjangka. Di sisi lain, algoritma Gaussian Naïve Bayes memperoleh tingkat akurasi yang lebih rendah, yaitu sebesar 84,45%, dengan nilai Precision sebesar 0,37, Recall sebesar 0,45, dan F1-Score sebesar 0,40.

Keunggulan model Decision Tree juga diperkuat oleh analisis Confusion Matrix, di mana model ini mampu meminimalisir tingkat kesalahan False Positive (FP) hingga 292 kasus, berbanding jauh dengan model Naïve Bayes yang menghasilkan 823 kasus False Positive. Hal ini menjadi faktor pembeda yang signifikan karena Decision Tree jauh lebih efektif dalam mengurangi kesalahan prediksi nasabah menolak menjadi nasabah menerima. Selain itu, berdasarkan visualisasi percabangan pohon keputusan (plot tree), dapat disimpulkan bahwa variabel durasi kontak panggilan telemarketing (duration) serta hasil dari kampanye pemasaran sebelumnya (poutcome) merupakan dua atribut prediktor yang paling mendominasi dalam menentukan keputusan nasabah mengambil produk deposit berjangka.

4.2 Saran

Guna mengoptimalkan hasil eksperimen serta penerapan praktis pemodelan di masa mendatang, terdapat beberapa saran yang dapat dipertimbangkan. Bagi pihak manajemen dan operasional perbankan, disarankan untuk mengimplementasikan model

prediksi berbasis Decision Tree ke dalam sistem Customer Relationship Management (CRM) untuk menyaring calon nasabah potensial sebelum melakukan panggilan t elemarketing, sehingga biaya dan durasi operasional pemasaran dapat dipangkas secara signifikan.

Selanjutnya, untuk pengembangan penelitian praktikum berikutnya, disarankan menerapkan teknik penanganan ketidakseimbangan kelas (class imbalance) seperti Synthetic Minority Over-sampling Technique (SMOTE) atau Random Under-Sampling untuk meningkatkan nilai Recall dan F1-Score pada kelas target positif. Terakhir, eksplorasi algoritma Ensemble Learning berbasis pohon seperti Random Forest atau XGBoost sangat direkomendasikan guna menggabungkan beberapa model prediktor sehingga diperoleh akurasi dan daya generalisasi data yang jauh lebih tinggi.

DAFTAR PUSTAKA

[1] Charbuty, B., & Abdulazeez, A. (2021). Classification based on decision tree algorithm for machine learning. *Journal of Applied Science and Technology Trends*, 2(01), 20–28. https://doi.org/10.38094/jastt20165

[2] Sarker, I. H. (2021). Machine learning: Algorithms, real-world applications and research directions. *SN Computer Science*, 2(3), 160. https://doi.org/10.1007/s42979-021-00592-x

[3] Peng, X., Sun, Z., & Liu, Q. (2022). Gaussian Naive Bayes and decision tree performance analysis on financial imbalanced datasets. *IEEE Access*, 10, 31450–31461. https://doi.org/10.1109/ACCESS.2022.3160124

[4] Buitinck, L., Louppe, G., Blondel, M., Pedregosa, F., Mueller, A., Grisel, O., Niculae, V., Prettenhofer, P., Gramfort, A., Grobler, J., & Varoquaux, G. (2023). API design for machine learning software: Experiences from the scikit-learn project and modern pipeline optimization. *Journal of Machine Learning Research*, 24(12), 1–18.

[5] Hossin, M., & Sulaiman, M. N. (2022). Comprehensive evaluation metrics and performance validation for binary classification in machine learning models. *International Journal of Data Mining & Knowledge Management Process*, 12(2), 45–59. https://doi.org/10.5121/ijdkp.2022.12204

[6] Mitchell, T. M., & Zhang, H. (2021). *Advanced Supervised Learning and Data Analytics in Financial Systems*. McGraw-Hill Education Academic.